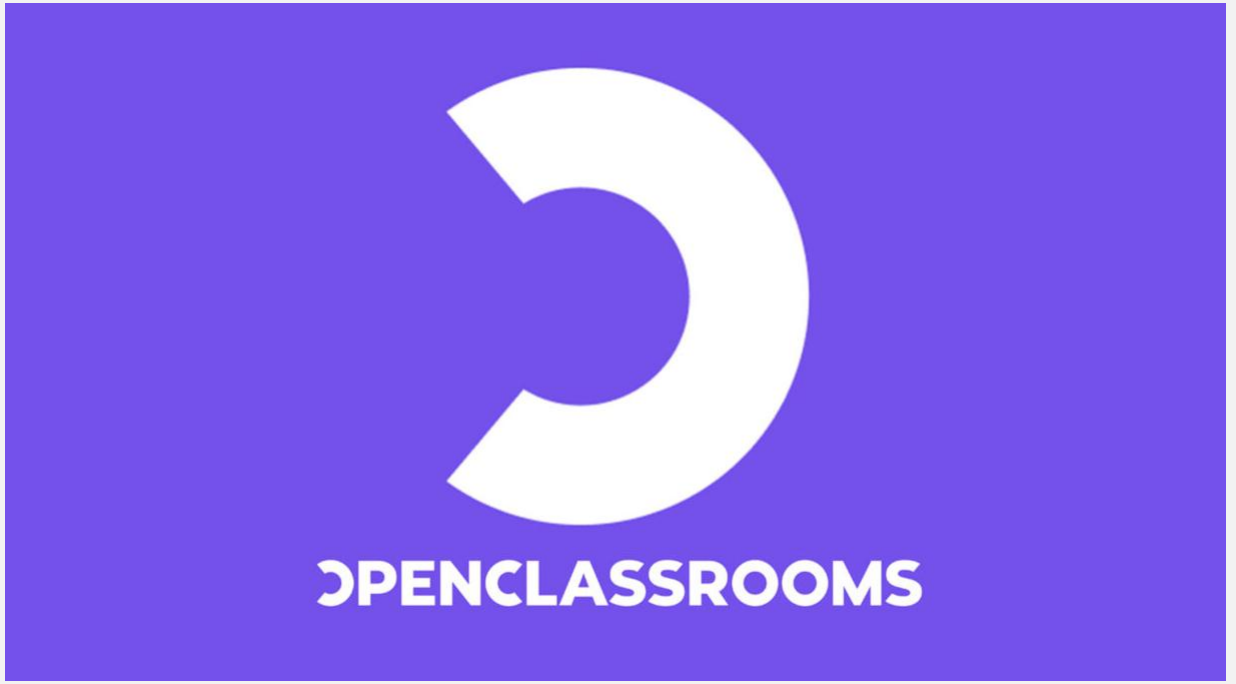
# Analyse sociodémographique des étudiants en Data




Présenté par Rémy D'AURA – Data Analyst

# Pourquoi cette analyse ?



•Comprendre le profil type de nos étudiants Data (Âge, Genre, Région).

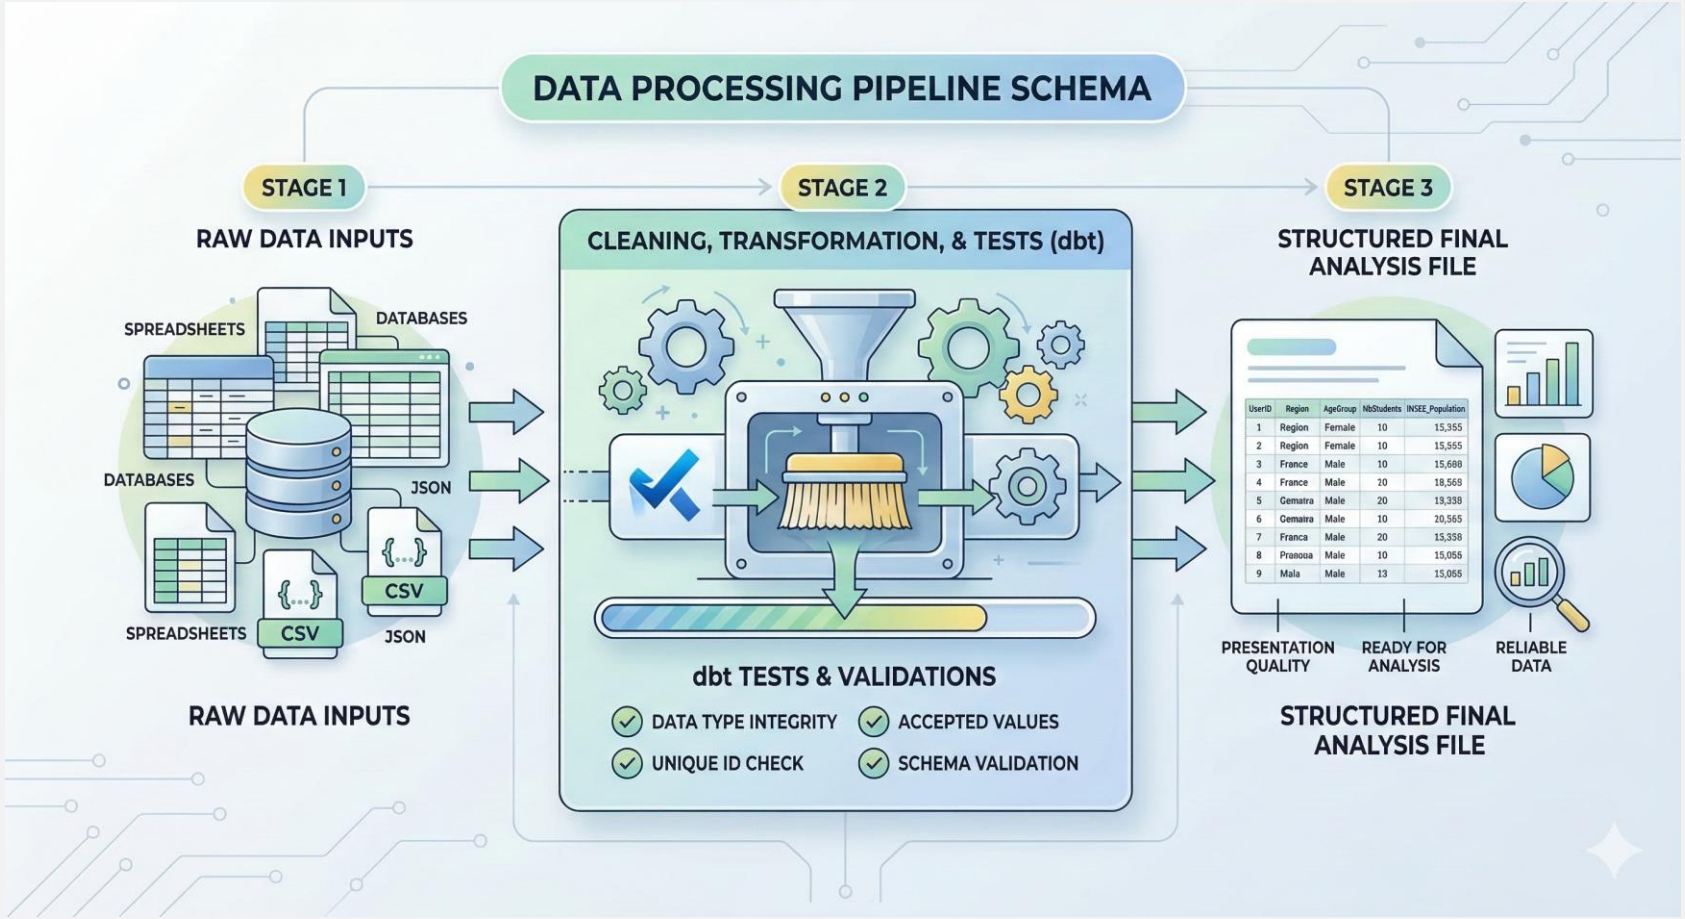


•Mesurer l'évolution de ces profils au fil des années.



•Comparer nos effectifs avec la population française officielle (données INSEE).

# Un processus de traitement automatisé




Mise en place d'un pipeline robuste pour traiter les données de manière reproductible.

# Respect strict du RGPD



- **Pseudonymisation :** Utilisation exclusive de l'identifiant USER_ID.
- **Minimisation :** Suppression des données non nécessaires à l'analyse.
- **Transparence :** Traitement des valeurs manquantes (ex: genre "Non renseigné").

# Fiabilisation : le traitement des réinscriptions







**Le problème :** Le fichier brut compte les *inscriptions*. Un étudiant réinscrit l'année suivante apparaissait en double et faussait les statistiques.

**La solution :** Création d'une règle automatisée pour ne conserver que l'inscription la plus récente par étudiant

**Résultat :** Des statistiques 100 % fiables, basées sur des individus uniques. (Règle dbt QUALIFY = 1 ligne par étudiant)

# Enrichissement avec les données de l'INSEE

Insee
Mesurer pour comprendre

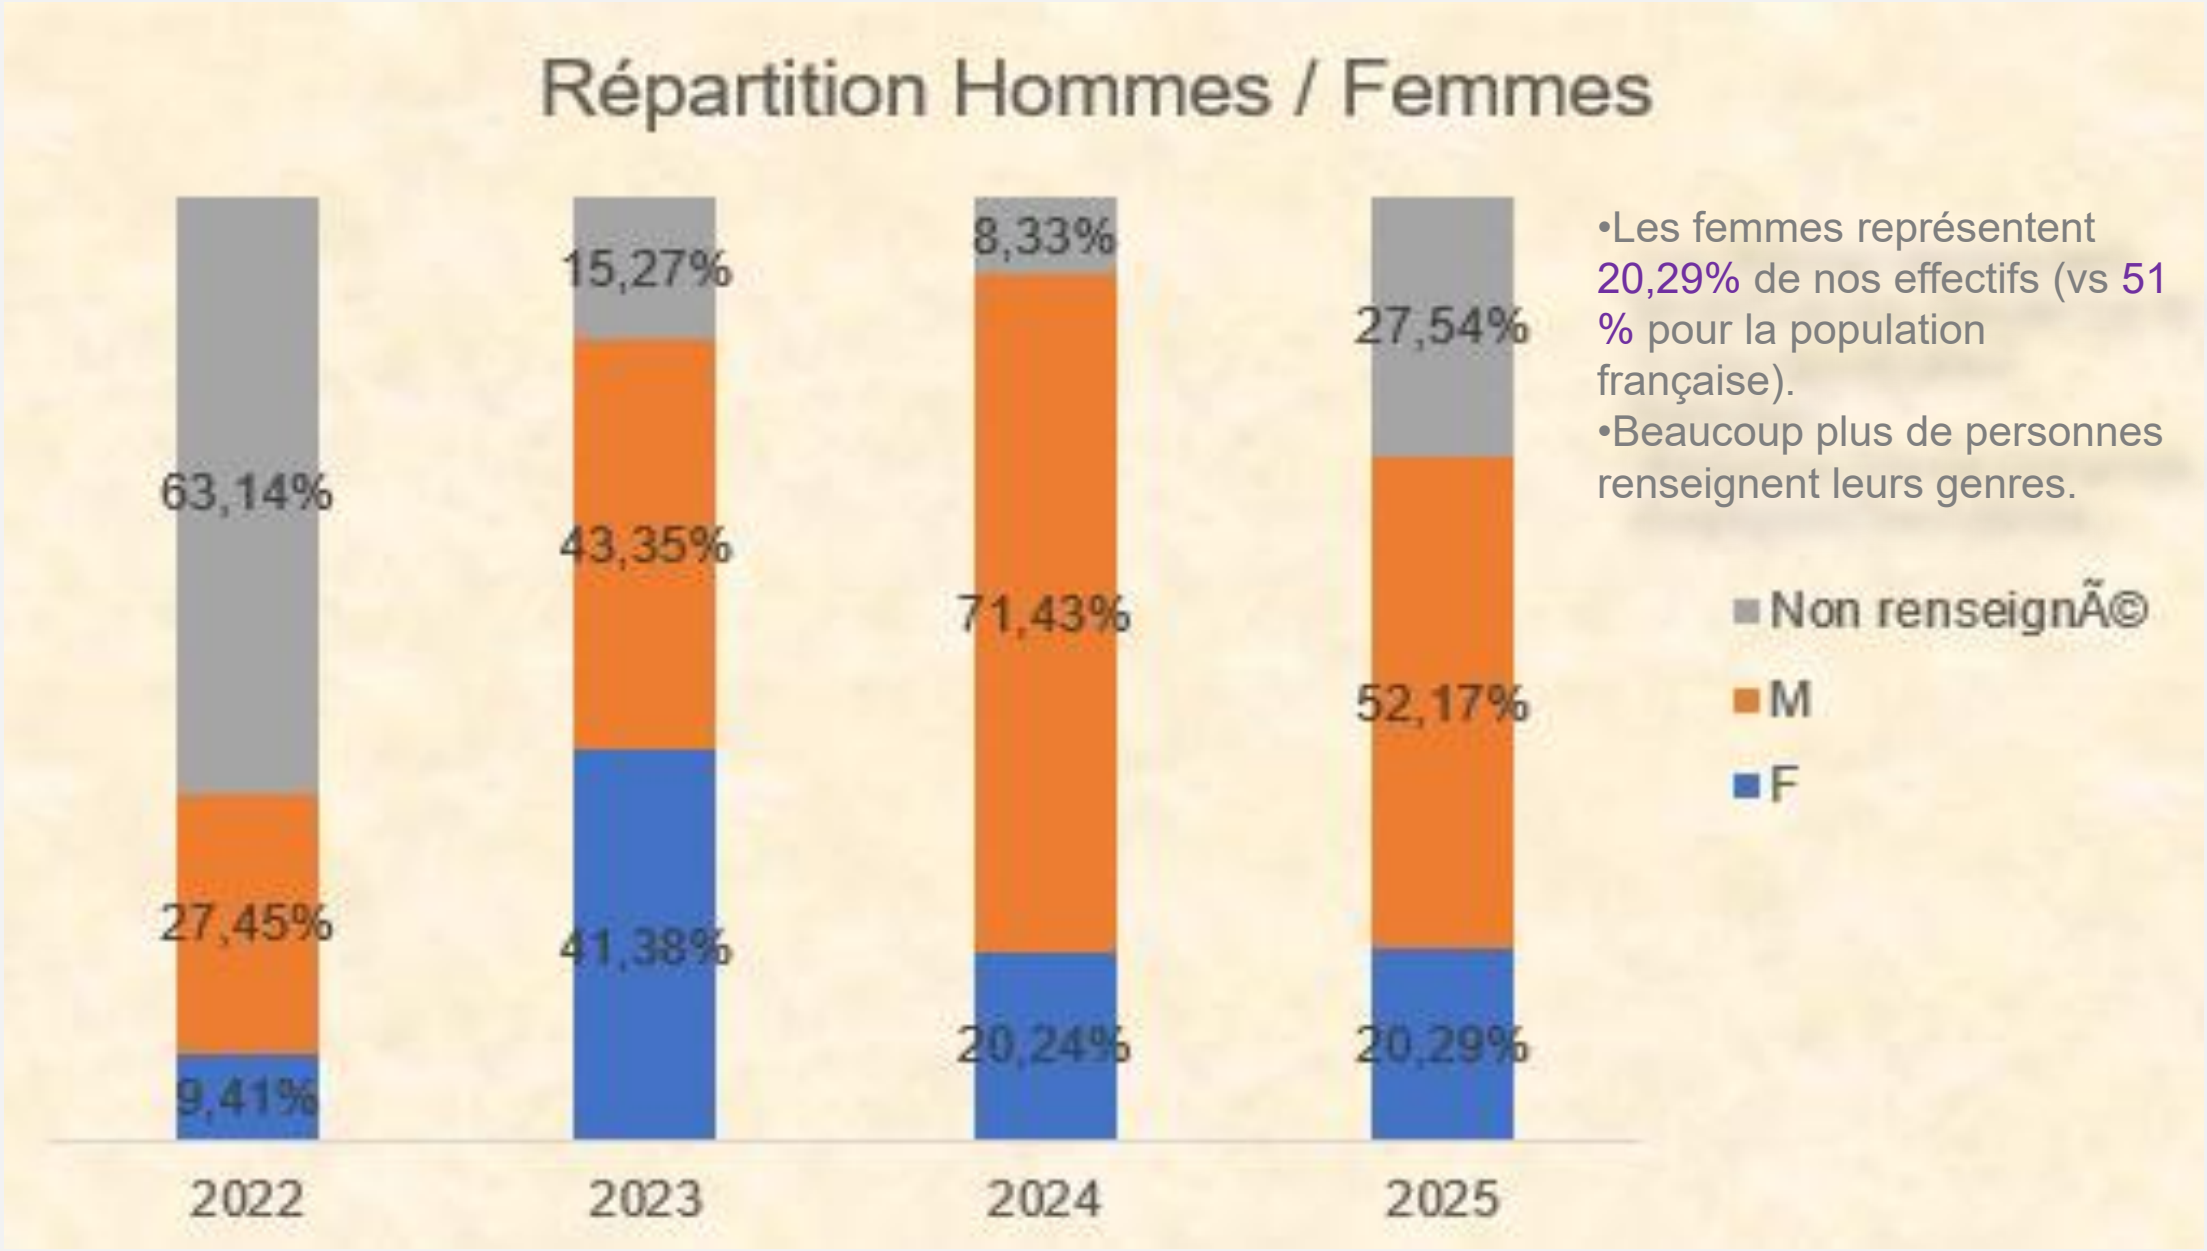
- Intégration d'un jeu de données gouvernemental.
- Harmonisation des nomenclatures (ex : correction syntaxique des régions comme "Centre-Val-de-Loire").
- Alignement des tranches d'âge pour permettre un point de comparaison fiable.

# Évolution globale



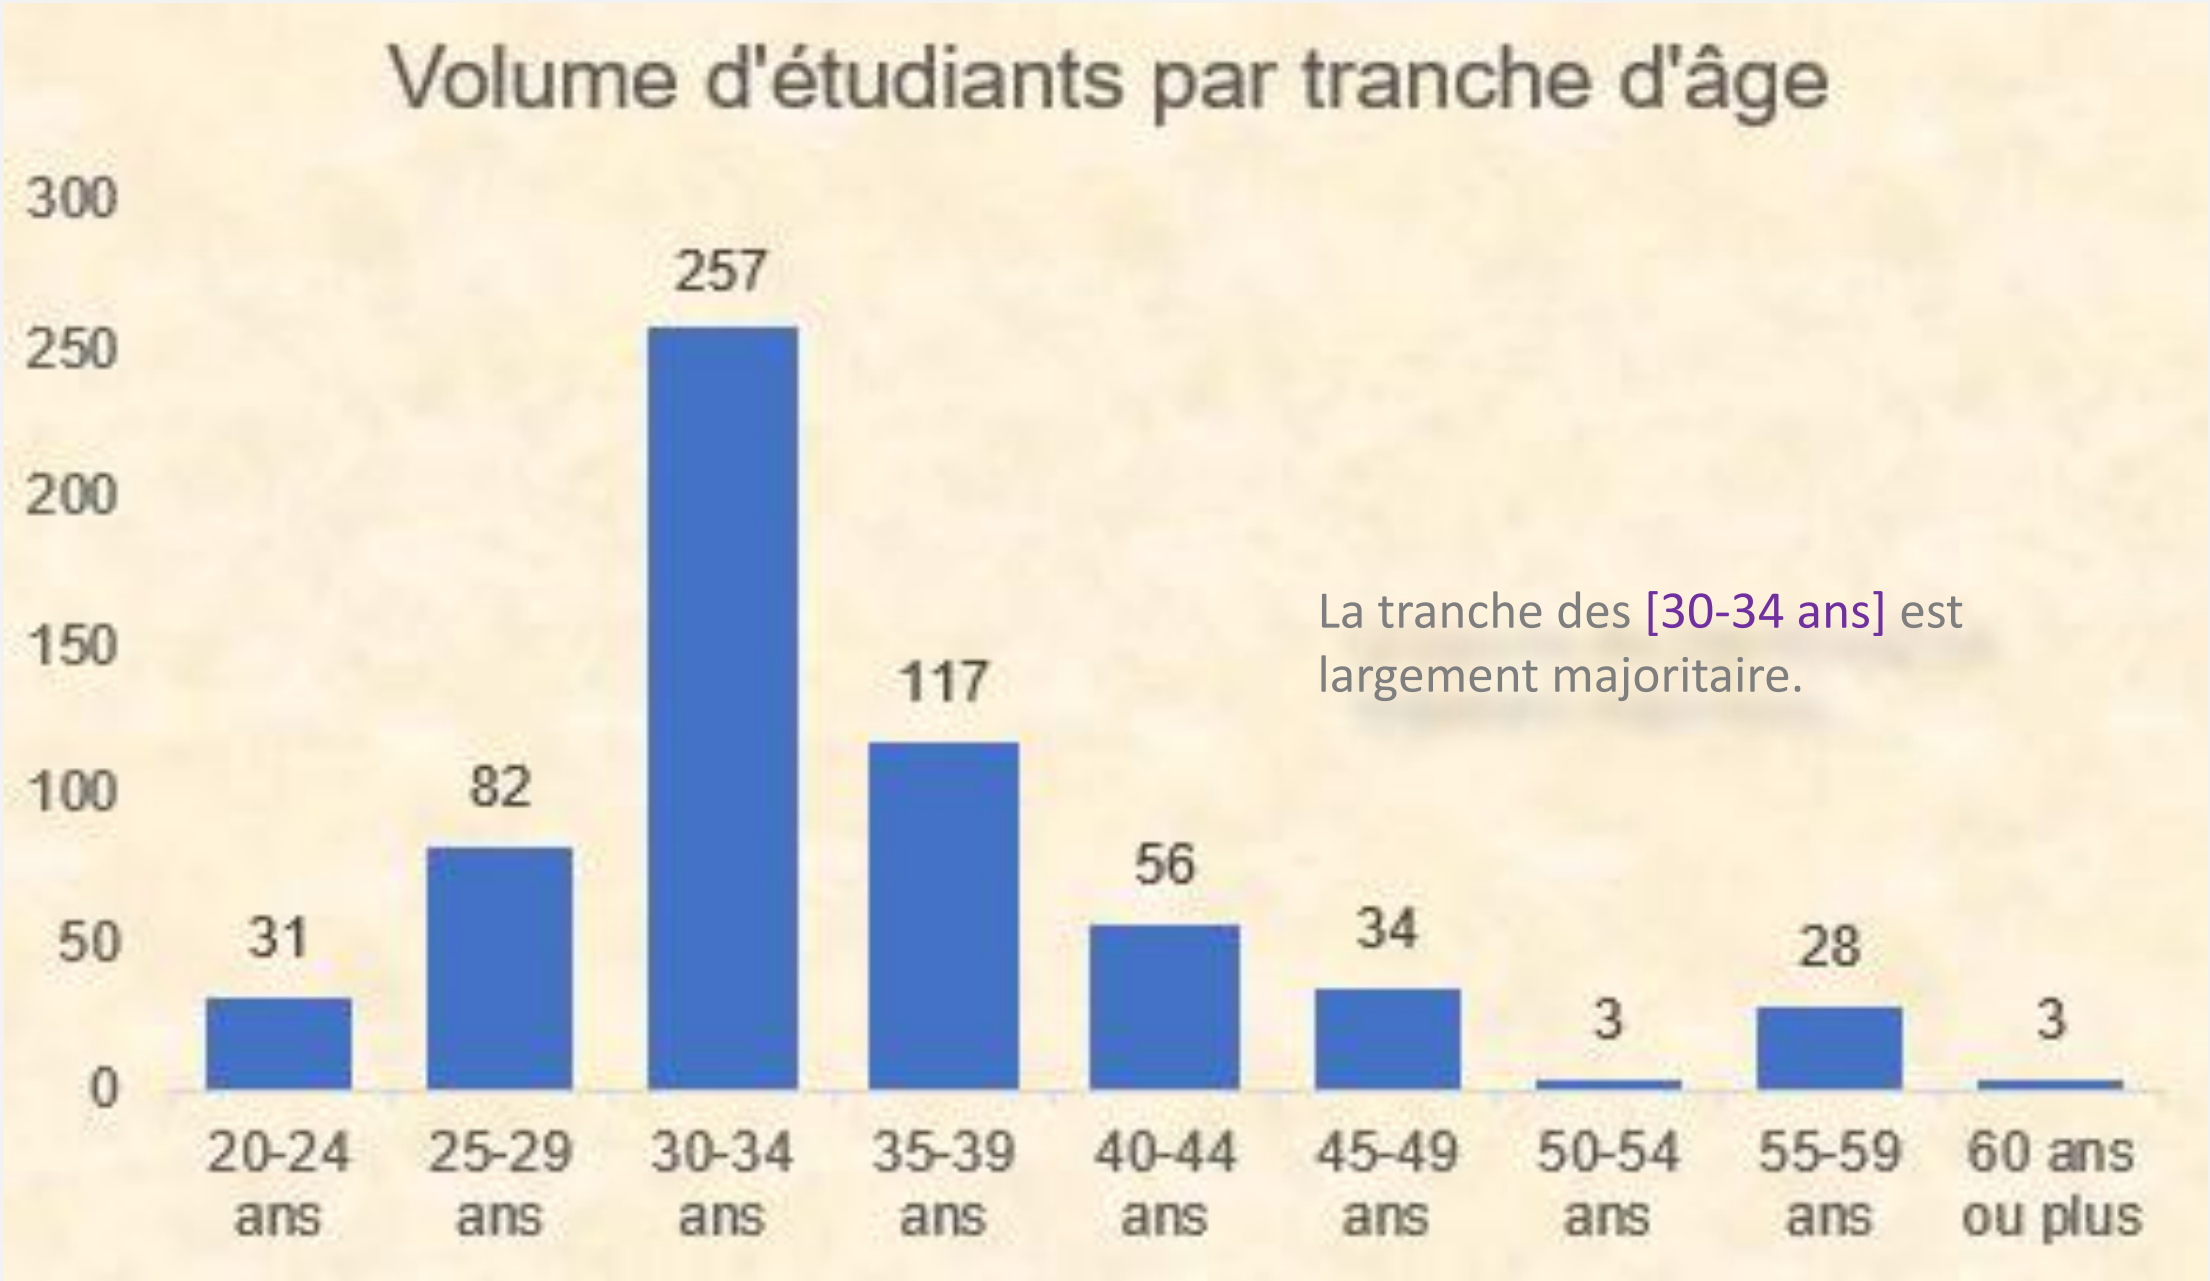

Le volume d'étudiants est passé de 255 en 2022 à 69 aujourd'hui.

# Focus sur la Parité



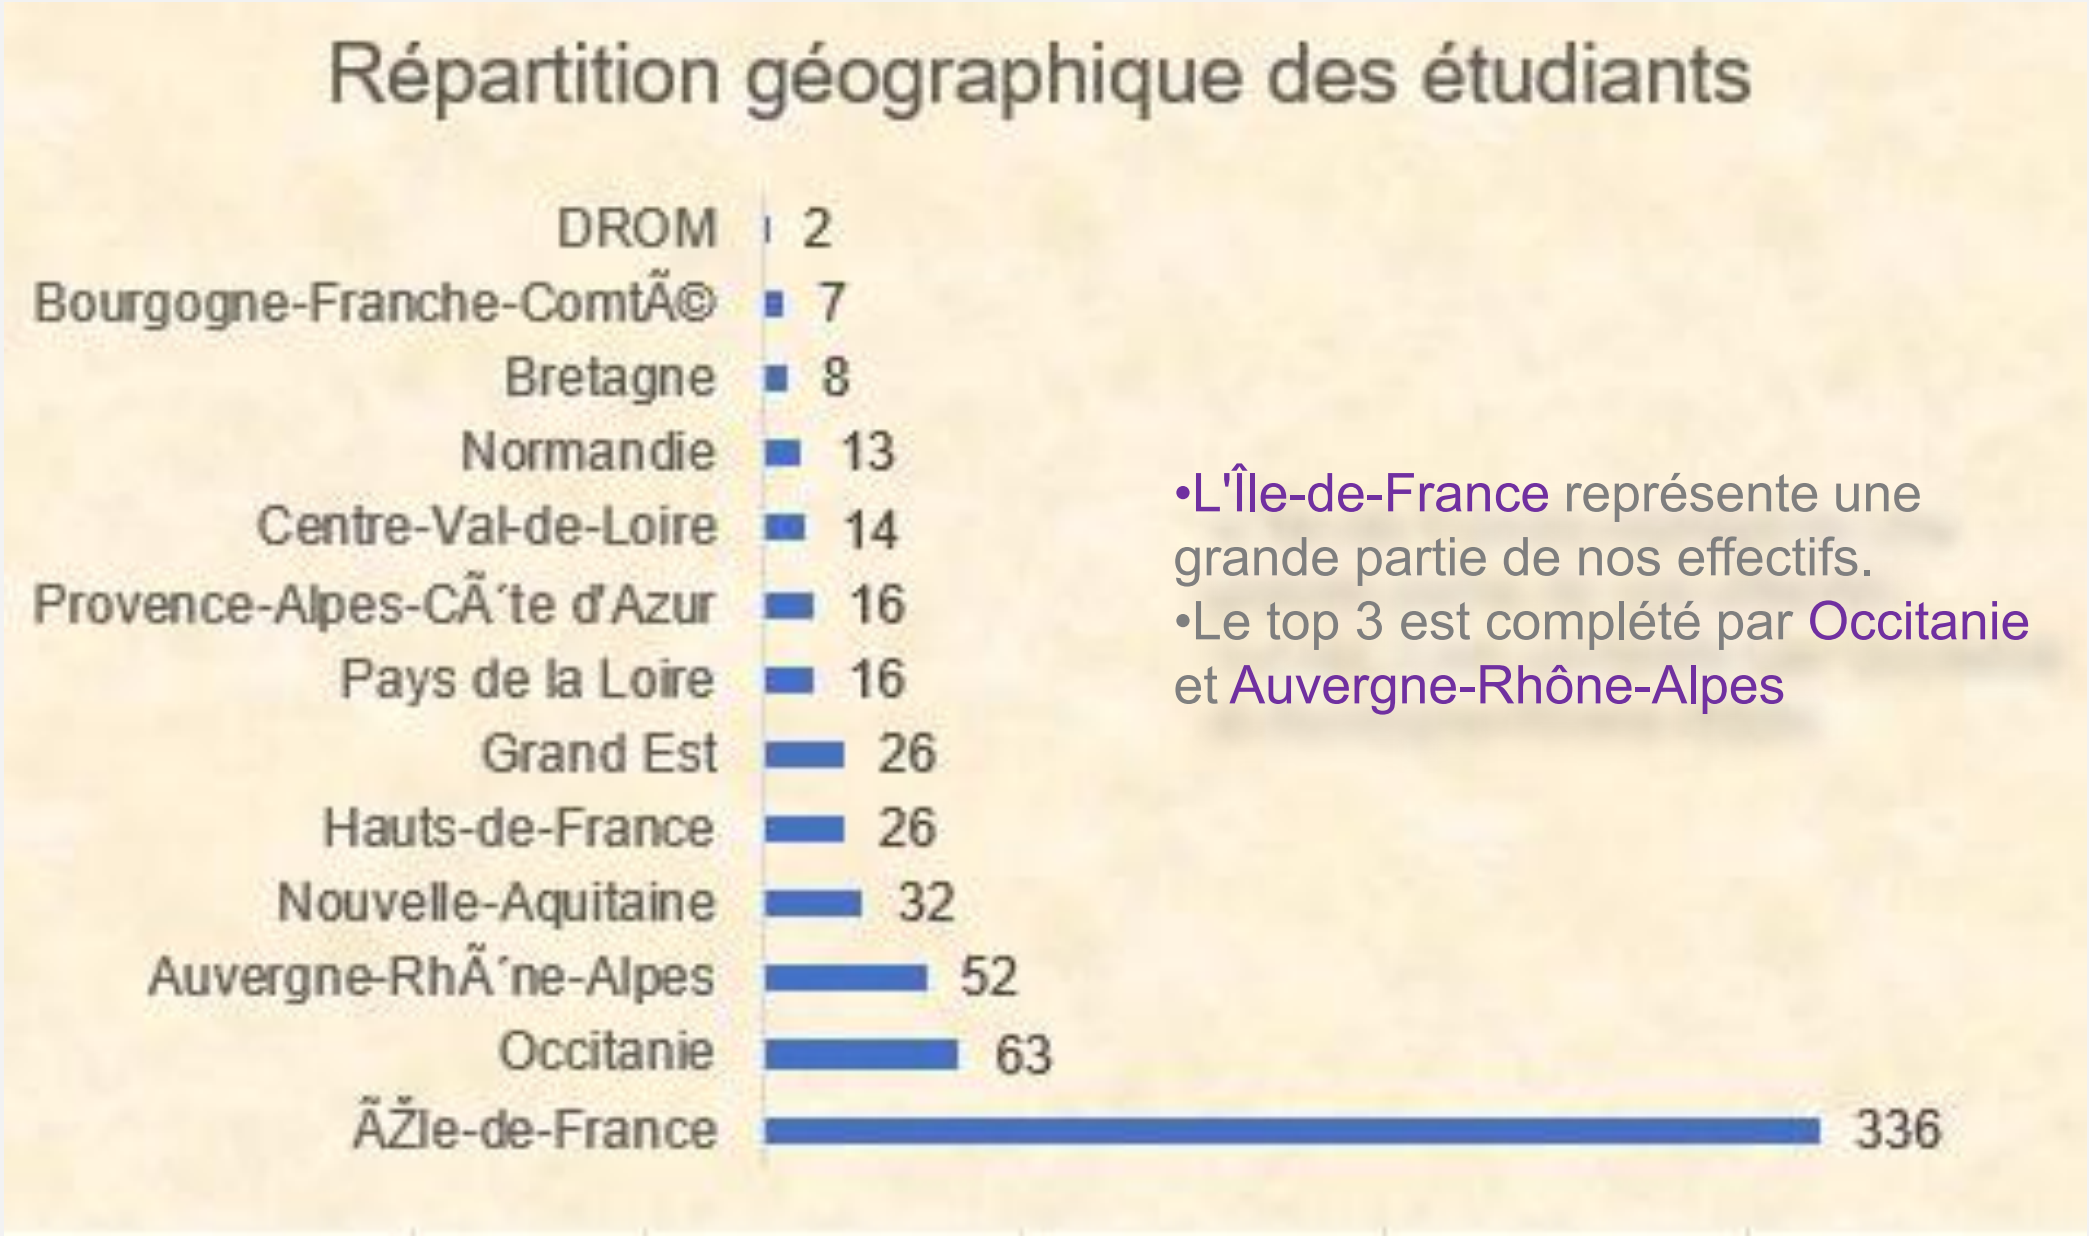

•Les femmes représentent 20,29% de nos effectifs (vs 51 % pour la population française).
•Beaucoup plus de personnes renseignent leurs genres.

# Focus sur l'Âge




La tranche des [30-34 ans] est largement majoritaire.

# Focus Géographique




- L'Île-de-France représente une grande partie de nos effectifs.
- Le top 3 est complété par Occitanie et Auvergne-Rhône-Alpes

# Recommandations stratégiques



- **Constat :** Chute des effectifs depuis le pic de 2022 (de 255 à 69 inscrits).

- **Action :** Auditer nos canaux d'acquisition, réévaluer notre positionnement face à la concurrence et relancer une campagne marketing d'urgence.



- **Constat :** Un pic exceptionnel à 41 % de femmes en 2023, retombé à 20 % aujourd'hui.

- **Action :** Identifier les actions spécifiques menées en 2023 (partenariats, bourses, communication ciblée) pour les réactiver immédiatement.



- **Constat :** Une hyper-concentration sur l'Île-de-France et un public très ciblé (30-34 ans).

- **Action :** Déployer des campagnes de reconversion professionnelles spécifiquement dans nos régions relais : Occitanie et Auvergne-Rhône-Alpes.

# Bilan technique

```
1 of 4 START test accepted_values_stg_students_gender__M__F__Non_renseign_ ..... [RUN]
1 of 4 PASS accepted_values_stg_students_gender__M__F__Non_renseign_ ........... [PASS in 2.22s]
2 of 4 START test not_null_mart_students_profiling_nb_students ................. [RUN]
2 of 4 PASS not_null_mart_students_profiling_nb_students ....................... [PASS in 0.79s]
3 of 4 START test not_null_stg_students_user_id ................................ [RUN]
3 of 4 PASS not_null_stg_students_user_id ..................................... [PASS in 0.14s]
4 of 4 START test unique_stg_students_user_id ................................... [RUN]
4 of 4 PASS unique_stg_students_user_id ....................................... [PASS in 0.57s]

Finished running 4 data tests in 0 hours 0 minutes and 8.65 seconds (8.65s).

Completed successfully

Done. PASS=4 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=4
```

- Tests de qualité automatisés intégrés au code.

- Architecture évolutive : le pipeline est prêt à ingérer les données de l'année prochaine en quelques secondes.

# Conclusion & Échanges



MERCI

"Place aux échanges & questions !"

Présenté par Rémy D'AURA – Data Analyst